Preparación de datos

DataSet y DataFrame 2
Tipos de datos 4
Preparación de datos 4
Integración 4
Análisis exploratorio de datos 4
Limpieza de datos (data cleaning) 5
Tratamiento de duplicados 6
Datos faltantes 6
Datos erróneos 7
Inconsistencias 8
Datos anómalos (outliers) 8
Actividad a desarrollar 9
Más información 9

DataSet y DataFrame

Un dataset (cuya traducción literal es “conjunto de datos”) es un conjunto de observaciones, cada una con un conjunto de atributos.

Se puede corresponder con una tabla de una base de datos relacional o con un fichero en formato CSV, donde cada fila es una instancia del conjunto de datos y cada columna representa una variable en particular. En un fichero en formato CSV (Comma Separated Values), además, en la primera fila suele estar el nombre de las columnas o atributos.

Existen muchos lugares en internet en la cual se pueden acceder a diferentes tipos de datasets con información relevante, por ejemplo:

- UN Data (https://data.un.org) es propio de las Naciones Unidas.
- Worldbank (https://data.worldbank.org) es el dataset del Banco Mundial, y se puede conocer información tanto de economía, como de salud, educación y desarrollo tecnológico.
- Google Public Data no solo posee sus propios datos, sino que recolecta la información de otros datasets.
- UCI Machine Learning Repository (https://archive.ics.uci.edu/datasets).
- Kaggle (https://www.kaggle.com/datasets).
- …

Una observación *x* perteneciente a un dataset tiene la siguiente forma:

$$(x^{(1)}, x^{(2)}, \dots, x^{(D)})$$

Donde son $x^{(1)}, x^{(2)}, \dots, x^{(D)}$ son los valores de los atributos del dataset y D el número de atributos o dimensionalidad del dataset.

Un dataset es un conjunto de observaciones:

$$\{x_1, x_2, \dots, x_N\} = \{(x_1^{(1)}, x_1^{(2)}, \dots, x_1^{(D)}), (x_2^{(1)}, x_2^{(2)}, \dots, x_2^{(D)}), \dots, (x_N^{(1)}, x_N^{(2)}, \dots, x_N^{(D)})\}$$

N es el número de observaciones o tamaño del dataset.

Un dataframe es un dataset en el que cada columna está etiquetada y organizada para trabajar de forma más potente.

Por ejemplo titanic.csv es un dataset. Cuando usamos pandas.read_csv() lo que estamos haciendo es leer un fichero csv y convertirlo en un DataFrame.

Python es el lenguaje que desde hace tiempo se ha impuesto en el campo del aprendizaje automático ya que es un lenguaje de programación simple, legible y versátil, y también por sus bibliotecas.

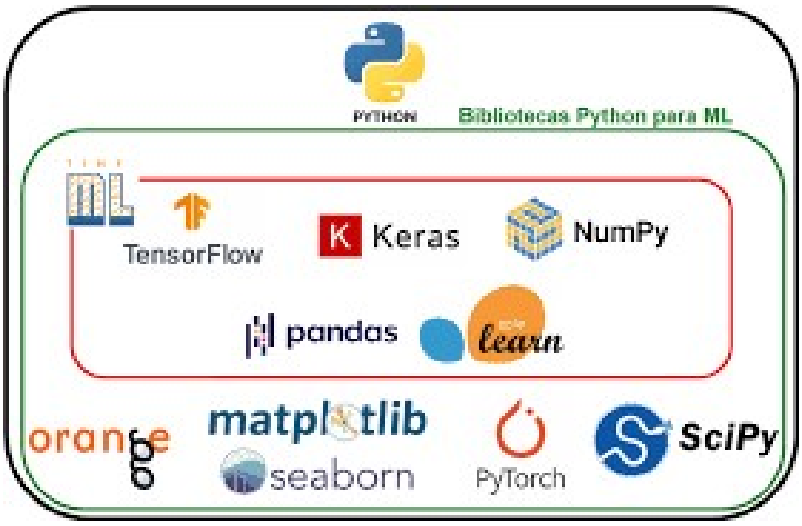

NumPy (Numerical Python) permite trabajar con objetos de matrices multidimensionales y es especialmente útil para tareas que requieren operaciones matemáticas en conjuntos de datos grandes.

Por ejemplo:

```
import numpy as np

# Creamos un array de dos dimensiones
 miArray = np.array ([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
print (miArray)
```

Pandas está diseñado para trabajar con estructuras de datos complejas y manipular datos. Proporciona dos estructuras de datos clave: Series y DataFrame. Una Serie es un objeto similar a una matriz unidimensional que puede contener cualquier tipo de datos, mientras que un DataFrame es una estructura de datos etiquetada bidimensional con columnas potencialmente de diferentes tipos.

Pandas destaca cuando se trata de manipulación y preparación de datos. Proporciona amplias capacidades para remodelar, dividir, cortar y agregar datos. También es una excelente herramienta para manejar datos de series temporales.

Por ejemplo:

```
import pandas as pd

# Creamos un DataFrame
data = {'Nombre': ['Juan', 'Ana', 'Pedro'],
        'Edad': [28, 24, 33]}
df = pd.DataFrame(data)
print(df)
```

O:

```
import pandas as pd

df = pd.read_csv (“titanic.csv”)
```

El código anterior carga el DataSet titanic.csv en un DataFrame de pandas.

La funcion read_csv de pandas tiene muchos parámetros para poder cargar ficheros en formato CSV con diversas opciones. Se puede encontrar toda la información en https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html.

Tipos de datos

El concepto de tipo de datos en Machine Learning no se corresponde directamente con el tipo de datos que se pueda utilizar en un una base de datos o en un lenguaje de programación.

Básicamente vamos a tener:

- Datos numéricos, que tienen significado como medida. A su vez, pueden ser:
    - Discretos, enteros como el número de habitaciones de una casa.
    - Continuos, como la temperatura.
- Datos categóricos, que representan categorías. Pueden ser números, pero no tienen valor matemático. Por ejemplo, el estado civil de una persona o la clase de un billete.

Preparación de datos

Integración

La integración o fusión de los datos consiste en la combinación de datos procedentes de múltiples fuentes, con el fin de crear una estructura de datos coherente y única que contenga mayor cantidad de información.

Análisis exploratorio de datos

El análisis exploratorio de datos (EDA) se centra en explorar los datos de manera descriptiva, utilizando herramientas visuales y estadísticas para obtener una comprensión inicial de la distribución de los datos, la presencia de valores atípicos, las relaciones entre variables y otros aspectos relevantes.

Implicaría:

- **Exploración inicial:** Esto puede incluir la revisión de la estructura de los datos, el tipo de variables presentes y la identificación de posibles problemas, como valores faltantes o inconsistentes.
- **Visualización de datos:** Se utilizan diversas herramientas gráficas, como histogramas, diagramas de dispersión, diagramas de caja y gráficos de barras, para

visualizar la distribución de variables y explorar relaciones entre ellas. Estas visualizaciones proporcionan una perspectiva intuitiva de los datos.

- **Estadísticas descriptivas:** Se calculan medidas estadísticas descriptivas, como la media, la mediana, la desviación estándar y cuartiles, para resumir las características numéricas de las variables. Estas estadísticas proporcionan una descripción cuantitativa de la tendencia central y la dispersión de los datos.

- **Identificación de valores atípicos:** Se buscan y analizan valores atípicos o extremos que podrían indicar errores en la recopilación de datos o revelar patrones interesantes. Técnicas como los diagramas de caja y los gráficos de dispersión pueden ser útiles en este contexto.

- **Análisis de relaciones:** Se exploran las relaciones entre variables, utilizando herramientas como matrices de dispersión o mapas de calor de correlación. Esto ayuda a comprender la interacción entre diferentes aspectos de los datos.

- **Generación de hipótesis:** A medida que se exploran los datos, pueden surgir hipótesis sobre patrones o tendencias interesantes que podrían ser investigadas más a fondo en etapas posteriores del análisis.

- **Iteración y refinamiento:** El proceso de EDA es iterativo. A medida que se descubren más aspectos de los datos, se pueden realizar ajustes en la exploración y se pueden formular nuevas preguntas para guiar el análisis continuo.

Limpieza de datos (data cleaning)

La limpieza de datos, o data cleaning en inglés, es el conjunto de procesos que permiten corregir o eliminar aquellas muestras erróneas de una base de datos. Estos procesos permiten identificar datos incompletos, incorrectos, inexactos o no pertinentes, con el fin de eliminarlos o corregirlos y así obtener bases de datos de mayor calidad.

Ejemplo de situaciones que generan datos erróneos:

Esta etapa es de vital importancia, de hecho, se estima que el 80 % del trabajo de un científico de datos es invertido en procesos de limpieza.

Los pasos de limpieza de datos comunes incluyen la corrección de:

- Duplicación de datos: eliminación de información duplicada.
- Datos faltantes: notificación y eliminación o atribución de datos faltantes.
- Datos irrelevantes: identificación de campos esenciales para un análisis concreto y eliminación de datos irrelevantes.
- Valores atípicos: repercuten sustancialmente en el rendimiento del modelo, por lo que es importante identificar y determinar las medidas apropiadas.
- Errores estructurales: corrección de errores tipográficos y otras incoherencias, y elaboración de datos en función de un patrón o una convención común.

Tratamiento de duplicados

Python simplifica la identificación y el tratamiento de los duplicados. Utilizando el método duplicated() de la biblioteca pandas de Python, se pueden identificar fácilmente las filas duplicadas en un DataFrame para examinarlas.

```
import pandas as pd

DataFrameDuplicate_rows = df[df.duplicated()]
```

Devuelve un DataFrame que contiene las filas duplicadas. La mayoría de los duplicados suelen ser copias exactas y pueden eliminarse llamando al método drop_duplicates().

En algunos casos, puede ser más apropiado fusionar registros duplicados, agregando información. Por ejemplo, si los duplicados representan varias entradas para la misma entidad, se pueden fusionar utilizando funciones de agregación.

Datos faltantes

Los datos vacíos o no definidos pueden presentarse en distintos formatos, como “”, “ “, “?” o null, pero en algunos contextos pueden incluso tomar valores numéricos como 0 o 999. Por tanto, será fundamental identificar en cada caso los valores que indiquen la pérdida de datos.

También es importante examinar las razones tras datos faltantes y actuar en consecuencia.

Razones sobre datos faltantes**:**

- Algunos valores faltantes expresan características relevantes. Por ejemplo, la falta de teléfono puede representar en muchos casos un deseo de que no se moleste a la persona en cuestión, o un cambio de domicilio reciente.
- Valores no existentes: muchos valores faltantes existen en la realidad, pero otros no. Por ejemplo:
  - El cliente que se acaba de dar de alta no tiene consumo medio de los últimos 12 meses.
  - Si la paciente no indica la edad de su primera revisión, puede indicar que esta es su primera revisión.
- Datos incompletos: si los datos vienen de fuentes diferentes, al combinarlos se suele hacer la unión externa (outer join) y no la interna (inner join), con lo que muchos datos faltantes representan que esas tuplas vienen de una de las dos fuentes y no existe en la otra.

Existen varias acciones a realizar ante datos faltantes:

- Ignorar: algunos algoritmos son robustos a datos faltantes (p.ej. árboles).
- Filtrar (eliminar o reemplazar) la columna: solución extrema, pero a veces existe otra columna dependiente con datos de mayor calidad.
- Filtrar la fila: claramente sesga los datos, porque muchas veces las causas de un dato faltante están relacionadas con casos o tipos especiales.
- Reemplazar el valor.
- Segmentar: Se segmentan las tuplas por los valores que tienen disponibles. Se obtienen modelos diferentes para cada segmento y luego se combinan.
- Modificar la política de calidad de datos y esperar hasta que los datos faltantes estén disponibles.

Pero nos centraremos en el caso de reemplazar el valor.

Una posibilidad es reemplazar el conjunto de valores perdidos por una misma constante o etiqueta, como por ejemplo «Desconocido». Esta técnica puede ser también útil cuando los valores perdidos tengan un significado común, como «No procede».

Otras aproximaciones reemplazan los registros perdidos por una misma medida:

- Para atributos numérico se usa la media o la mediana, dependiendo de la distribución de los datos. Esta media se puede calcular para toda la muestra o para cada una de las clases o categorías que la describan. Por ejemplo, se podrían calcular por separado las medias de hombres y mujeres.
- Para atributos categóricos se usaría la moda.

Finalmente, otras aproximaciones se basan en la implementación de algoritmos para predecir los valores perdidos. Algunos de estos métodos son las regresiones, las inferencias basadas en modelos bayesianos o los árboles de decisión.

Aunque las aproximaciones que tratan de imputar valores perdidos se presentan como una alternativa particularmente interesante con el objetivo de no perder información útil, deberán aplicarse con cautela y utilizando métodos adecuados, para no introducir error y falsear los resultados.

Datos erróneos

La solución dependerá del tipo de problemática:

Una posibilidad es sustituir los datos incorrectos mediante imputación, como si se tratara de un valor omitido, o eliminarlos por completo del conjunto de datos, según las circunstancias.

Las incoherencias en el formato de los datos pueden corregirse utilizando algunos métodos como: para eliminar los espacios iniciales y finales de una cadena, se puede utilizar el método .strip(). Los métodos .upper() y .lower() normalizarán las mayúsculas y minúsculas en las cadenas. Y la conversión de fechas a datetimes mediante pd.to_datetime normalizará el formato de las fechas.

Otras correcciones de incoherencias de formato son:

- Conversión de unidades
- Normalización del correo electrónico, el teléfono y la dirección
- Eliminar la puntuación de las cadenas
- Utilizar el mapeo de valores para tratar las abreviaturas comunes

Inconsistencias

Un problema grave que afecta a varios métodos de aprendizaje predictivo son los registros inconsistentes, es decir, dos o más registros con los mismos valores en los atributos, pero diferente valor en el atributo clase.

Algunas técnicas no soportan las inconsistencias en los datos. Por lo que se deben eliminar unificando (siempre que se pueda) los registros en una única clase.

Datos anómalos (outliers)

Los outliers son aquellos datos que se encuentran muy alejados de la distribución normal de una variable o población.

El problema que existe es que estos valores pueden afectar de forma adversa los resultados de los análisis posteriores, al incrementar el error en la varianza de los datos y sesgar significativamente los cálculos y estimaciones.

Estos valores pueden aparecer por diferentes razones, por lo que se aplican distintas soluciones en función del contexto. En algunos casos, estos datos serán legítimos y formarán parte de la muestra, por lo que no se deberá modificar el conjunto de datos y se contemplarán los outliers en el análisis.

En otros casos, pueden ser debidos al uso de diferentes unidades de medida. Por ejemplo, al integrar los conjuntos de datos procedentes de las diferentes tiendas de una cadena, nos podemos encontrar que, aunque la mayoría de las tiendas reportan el precio de sus productos en euros, la tienda que se encuentra en el aeropuerto de Ciudad de México ha reportado los precios en pesos mexicanos. Aunque estos precios se verán como outliers inicialmente, solo será necesario aplicar la conversión de pesos a euros en ese grupo de datos para que el conjunto sea coherente.

Aunque la decisión sobre qué se considera un valor extremo ha sido un tema controvertido durante décadas, generalmente se considera que cuando un valor se encuentra alejado 3 desviaciones estándar con respecto a la media del conjunto es un outlier. Por ello, en muchos trabajos se utiliza la representación de los datos mediante gráficos de cajas (boxplots), con el objetivo de detectar dichos outliers.

También hay otros métodos de detección de outliers, como por ejemplo, técnicas de clustering que permiten identificar conjuntos de datos que se alejen significativamente de los valores esperados de la muestra.

En los casos en los que los outliers sean errores se pueden realizar las siguientes acciones:

- Ignorar: algunos algoritmos son robustos a datos anómalos (p.ej. Árboles de decisión)
- Filtrar (eliminar o reemplazar) la columna: solución extrema, pero a veces existe otra columna dependiente con datos de mayor calidad.
- Filtrar la fila: claramente sesga los datos, porque muchas veces las causas de un dato erróneo están relacionadas con casos o tipos especiales.
- Reemplazar el valor:
    - Por el valor 'nulo' si el algoritmo lo trata bien
    - Por máximos o mínimos, dependiendo por donde es el outlier
    - Por medias.
    - A veces se puede predecir a partir de otros datos, utilizando cualquier técnica de Inteligencia Artificial.
- Discretizar: transformar un valor continuo en uno discreto (p.ej. muy alto, alto, medio, bajo, muy bajo) hace que los outliers caigan en 'muy alto' o 'muy bajo' sin mayores problemas.

Actividad a desarrollar

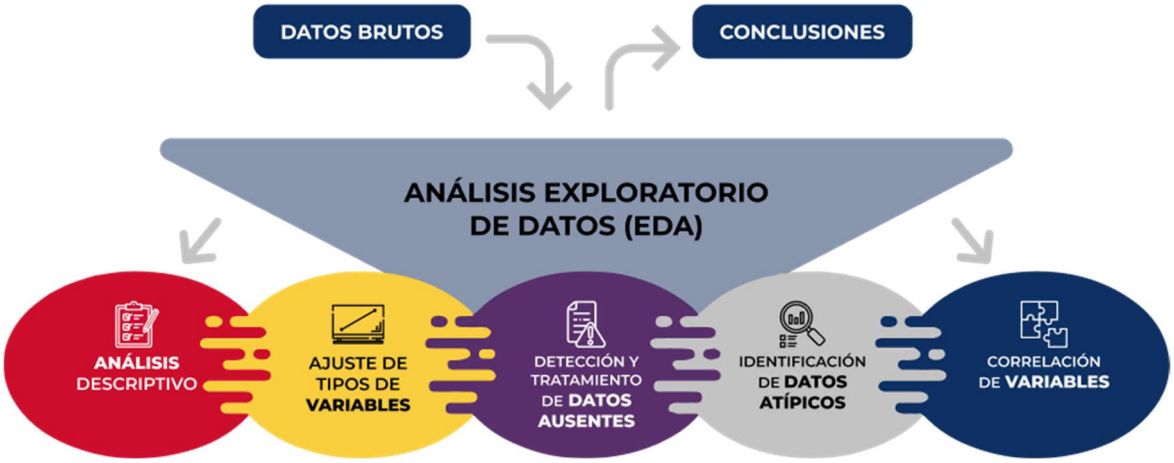

https://datos.gob.es/es/conocimiento/guia-practica-de-introduccion-al-analisis-exploratorio-de-datos-en-r

Más información

https://www.sapalomera.cat/moodlecf/apunts/iabd/bigdata/apuntes13.html